

信息理论第二次作业

以下各题对数均取 $\log_2$

3.1

试证明最长长度不大于 N 的 D 元不等长码至多有 $\frac{D(D^N-1)}{D-1}$ 个码字。

解： 设码符号表为

$$\mathcal{D} = \{0, 1, \dots, D-1\}.$$

长度为 n 的 D 元序列共有 D^n 个。因此，长度不大于 N 且长度至少为 1 的所有可能码字总数为

$$D + D^2 + \dots + D^N.$$

一个码中不同消息对应的码字必须互不相同，所以码字数不可能超过所有可用字符串的总数。于是

$$M \leq \sum_{n=1}^N D^n = D \frac{D^N - 1}{D - 1} = \frac{D(D^N - 1)}{D - 1}.$$

故最长长度不大于 N 的 D 元不等长码至多有

$$\frac{D(D^N - 1)}{D - 1}$$

个码字。

3.3

下面哪些码是唯一可译的？

- (a) $\{0, 10, 11\}$
- (b) $\{0, 01, 11\}$
- (c) $\{0, 01, 10\}$
- (d) $\{0, 01\}$
- (e) $\{00, 01, 10, 11\}$
- (f) $\{110, 11, 10\}$
- (g) $\{110, 100, 00, 10\}$

解： 采用 Sardinas-Patterson 判别法。记由前缀关系产生的后缀集合为 $S_1, S_2, \dots$ 。若某个 S_k 中出现原码字，则码不是唯一可译的；若后缀集合为空或进入循环且从未出现原码字，则码是唯一可译的。

(a) $\{0, 10, 11\}$ 是即时码，因为没有一个码字是另一个码字的前缀，所以是唯一可译码。

(b) $\{0, 01, 11\}$ 中有

$$S_1 = \{1\}, \quad S_2 = \{1\} = S_1.$$

后缀集合进入循环，且没有出现原码字，所以是唯一可译码。

(c) $\{0, 01, 10\}$ 中有

$$S_1 = \{1\}, \quad S_2 = \{0\}.$$

因为 0 是原码字，所以不是唯一可译码。事实上

$$010 = 010 = 010,$$

存在两种不同译法。

(d) $\{0, 01\}$ 中有

$$S_1 = \{1\}, \quad S_2 = \emptyset.$$

后缀集合为空，所以是唯一可译码。

(e) $\{00, 01, 10, 11\}$ 是等长码，所以是唯一可译码。

(f) $\{110, 11, 10\}$ 中有

$$S_1 = \{0\}, \quad S_2 = \emptyset.$$

后缀集合为空，所以是唯一可译码。

(g) $\{110, 100, 00, 10\}$ 中有

$$S_1 = \{0\}, \quad S_2 = \{0\} = S_1.$$

后缀集合进入循环，且没有出现原码字，所以是唯一可译码。

综上，唯一可译码为 (a)、(b)、(d)、(e)、(f)、(g)；不是唯一可译码的是 (c)。

3.4

确定下面码是否唯一可译，若不是则构造一个模糊序列。

(a)

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
010	0001	0110	1100	00011	00110	11110	101011

(b)

x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
<i>abc</i>	<i>abcd</i>	<i>e</i>	<i>dba</i>	<i>bace</i>	<i>ceac</i>	<i>ceab</i>	<i>eabd</i>

解：

(a) 记码字集合为

$$C = \{010, 0001, 0110, 1100, 00011, 00110, 11110, 101011\}.$$

用 Sardinas-Patterson 判别法计算后缀集合：

$$S_1 = \{1\},$$

$$S_2 = \{100, 1110, 01011\},$$

$$S_3 = \{11\},$$

$$S_4 = \{110, 00\},$$

$$S_5 = \{0, 011, 01, 110\},$$

$$S_6 = \{0110, 110, 0011, 001, 0, 10\}.$$

因为

$$0110 = x_3 \in C$$

出现在后缀集合中，所以该码不是唯一可译码。

一个模糊序列为

$$000110101111000110.$$

它有两种不同分解：

$$000110101111000110 = 0001\ 101011\ 1100\ 0110 = x_2x_8x_4x_3,$$

同时

$$000110101111000110 = 00011\ 010\ 11110\ 00110 = x_5x_1x_7x_6.$$

因此它是一个模糊序列。

(b) 记码字集合为

$$C = \{abc, abcd, e, dba, bace, ceac, ceab, eabd\}.$$

用 Sardinas-Patterson 判别法计算：

$$S_1 = \{d, abd\},$$

$$S_2 = \{ba\},$$

$$S_3 = \{ce\},$$

$$S_4 = \{ac, ab\},$$

$$S_5 = \{c, cd\},$$

$$S_6 = \{eac, eab\},$$

$$S_7 = \{ac, ab, d\},$$

$$S_8 = \{c, cd, ba\},$$

$$S_9 = \{eac, eab, ce\},$$

$$S_{10} = \{ac, ab, d\} = S_7.$$

后缀集合从 S_7 开始进入循环，且没有任何一个 S_k 含有原码字，所以该码是唯一可译码。

3.6

令 DMS 为

$$U = \begin{pmatrix} a_1 & a_2 & a_3 & a_4 & a_5 & a_6 & a_7 & a_8 & a_9 & a_{10} \\ 0.16 & 0.14 & 0.13 & 0.12 & 0.1 & 0.09 & 0.08 & 0.07 & 0.06 & 0.05 \end{pmatrix}$$

(a) 求二元 Huffman 码, 计算 $\bar{n}$ 和 η 。(b) 求三元 Huffman 码, 计算 $\bar{n}$ 和 η 。

解: 信源熵为

$$H(U) = - \sum_{i=1}^{10} p_i \log p_i \approx 3.23438 \text{ bit/符号}.$$

(a) 按二元 Huffman 编码法, 每次合并两个最小概率, 可得到一种二元 Huffman 码如下:

信源符号	a_1	a_2	a_3	a_4	a_5	a_6	a_7	a_8	a_9	a_{10}
p_i	0.16	0.14	0.13	0.12	0.10	0.09	0.08	0.07	0.06	0.05
码字	111	101	100	011	001	000	1101	1100	0101	0100
n_i	3	3	3	3	3	3	4	4	4	4

因此平均码长为

$$\bar{n}_2 = \sum_{i=1}^{10} p_i n_i = 3(0.16 + 0.14 + 0.13 + 0.12 + 0.10 + 0.09) + 4(0.08 + 0.07 + 0.06 + 0.05).$$

即

$$\bar{n}_2 = 3.26.$$

二源码的编码效率为

$$\eta_2 = \frac{H(U)}{\bar{n}_2} = \frac{3.23438}{3.26} \approx 0.99214.$$

(b) 三元 Huffman 编码需要每次合并 3 个结点。因为信源符号数 10 不满足

$$10 \equiv 1 \pmod{3-1},$$

所以先补充一个概率为 0 的虚符号, 使总符号数变为 11。每次合并三个最小概率, 可得到一种三元 Huffman 码如下:

信源符号	a_1	a_2	a_3	a_4	a_5	a_6	a_7	a_8	a_9	a_{10}
p_i	0.16	0.14	0.13	0.12	0.10	0.09	0.08	0.07	0.06	0.05
码字	22	21	20	12	10	02	01	00	112	111
n_i	2	2	2	2	2	2	2	2	3	3

因此平均码长为

$$\bar{n}_3 = \sum_{i=1}^{10} p_i n_i = 2(0.16 + 0.14 + 0.13 + 0.12 + 0.10 + 0.09 + 0.08 + 0.07) + 3(0.06 + 0.05).$$

即

$$\bar{n}_3 = 2.11.$$

三元码的效率为

$$\eta_3 = \frac{H(U)}{\bar{n}_3 \log 3} = \frac{3.23438}{2.11 \log 3} \approx 0.96714.$$

等价地，也可先把信源熵换成三元单位：

$$H_3(U) = \frac{H(U)}{\log 3} \approx 2.04067,$$

从而

$$\eta_3 = \frac{H_3(U)}{\bar{n}_3} \approx \frac{2.04067}{2.11} \approx 0.96714.$$

3.10

考虑一个概率分布为

$$\begin{pmatrix} x_1 & x_2 & x_3 & x_4 \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{4} & \frac{1}{12} \end{pmatrix}$$

的随机变量。

(a) 对该随机变量构成一个 Huffman 码。(b) 证明存在 2 个不同的最佳码长集合，即证明码长集合为 $(1, 2, 3, 3)$ 和 $(2, 2, 2, 2)$ 都是最佳的。(c) 证明某些符号的最佳码字长度可能超出 Shannon 编码码长 $\left\lceil \log \frac{1}{p(x)} \right\rceil$ 。

解：

(a) 按概率从小到大合并：

$$\frac{1}{12} + \frac{1}{4} = \frac{1}{3}, \quad \frac{1}{3} + \frac{1}{3} = \frac{2}{3}, \quad \frac{1}{3} + \frac{2}{3} = 1.$$

因此可得一种 Huffman 码为

信源符号	x_1	x_2	x_3	x_4
p_i	$\frac{1}{3}$	$\frac{1}{3}$	$\frac{1}{4}$	$\frac{1}{12}$
码字	0	10	110	111
n_i	1	2	3	3

平均码长为

$$\bar{n} = \frac{1}{3} \cdot 1 + \frac{1}{3} \cdot 2 + \frac{1}{4} \cdot 3 + \frac{1}{12} \cdot 3 = 2.$$

(b) 先证明任意二元唯一可译码的平均码长都不小于 2。由 Kraft 不等式，任意唯一可译码的码长 n_i 必须满足

$$\sum_i 2^{-n_i} \leq 1.$$

若没有长度为 1 的码字，则所有码长都至少为 2，显然

$$\bar{n} \geq 2.$$

若有一个长度为 1 的码字，则二元码中最多只能有一个长度为 1 的码字。为了使平均码长尽量小，应把这个最短码字分给概率最大的符号。剩下三个码字的 Kraft 容量至多为

$$1 - \frac{1}{2} = \frac{1}{2}.$$

因此剩下三个码字中至多有一个码字长度为 2；否则两个长度为 2 的码字已经占满容量 $\frac{1}{2}$ ，无法再放入第三个码字。于是剩下三个码字的最短可能码长为 2, 3, 3。将它们按概率从大到小分配时，最小平均码长为

$$\frac{1}{3} \cdot 1 + \frac{1}{3} \cdot 2 + \frac{1}{4} \cdot 3 + \frac{1}{12} \cdot 3 = 2.$$

故任意唯一可译码都有

$$\bar{n} \geq 2.$$

另一方面，码长集合 (1, 2, 3, 3) 对应上面 (a) 中的 Huffman 码，平均码长为 2；码长集合 (2, 2, 2, 2) 可取等长码

$$x_1 \mapsto 00, \quad x_2 \mapsto 01, \quad x_3 \mapsto 10, \quad x_4 \mapsto 11,$$

其平均码长也为

$$\bar{n} = 2.$$

因为二者都达到最小可能平均码长 2，所以 (1, 2, 3, 3) 和 (2, 2, 2, 2) 都是最佳码长集合。

(c) 在 (a) 的最佳 Huffman 码中，符号 x_3 的码长为

$$n_3 = 3.$$

但

$$\left\lceil \log \frac{1}{p(x_3)} \right\rceil = \lceil \log 4 \rceil = 2.$$

因而在某个最佳码中，符号 x_3 的最佳码字长度满足

$$n_3 = 3 > 2 = \left\lceil \log \frac{1}{p(x_3)} \right\rceil.$$

这说明 Shannon 编码码长只是可构造码长的一种逐符号上界，并不要求每一个最佳码中每个符号的码长都不超过该 Shannon 码长。

3.11

令 DMS 为

$$U = \begin{pmatrix} x_1 & x_2 & x_3 & x_4 & x_5 & x_6 & x_7 & x_8 & x_9 & x_{10} & x_{11} & x_{12} & x_{13} \\ 0.2 & 0.18 & 0.1 & 0.1 & 0.1 & 0.061 & 0.059 & 0.04 & 0.04 & 0.04 & 0.04 & 0.03 & 0.01 \end{pmatrix}$$

(a) 求二元 Huffman 码，计算 $\bar{n}$ 和 η 。(b) 求三元 Huffman 码，计算 $\bar{n}$ 和 η 。

解：信源熵为

$$H(U) = - \sum_{i=1}^{13} p_i \log p_i \approx 3.35454 \text{ bit/符号}.$$

(a) 按二元 Huffman 编码法，每次合并两个最小概率，可得到一种二元 Huffman 码如下：

信源符号	x_1	x_2	x_3	x_4	x_5	x_6	x_7
p_i	0.20	0.18	0.10	0.10	0.10	0.061	0.059
码字	00	111	010	011	100	1010	11011
n_i	2	3	3	3	3	4	5

信源符号	x_8	x_9	x_{10}	x_{11}	x_{12}	x_{13}
p_i	0.04	0.04	0.04	0.04	0.03	0.01
码字	10110	10111	11000	11001	110101	110100
n_i	5	5	5	5	6	6

因此平均码长为

$$\begin{aligned}\bar{n}_2 &= 2(0.20) + 3(0.18 + 0.10 + 0.10 + 0.10) + 4(0.061) \\ &\quad + 5(0.059 + 0.04 + 0.04 + 0.04 + 0.04) + 6(0.03 + 0.01) \\ &= 3.419.\end{aligned}$$

二元码的编码效率为

$$\eta_2 = \frac{H(U)}{\bar{n}_2} = \frac{3.35454}{3.419} \approx 0.98115.$$

(b) 三元 Huffman 编码需要每次合并 3 个结点。由于

$$13 \equiv 1 \pmod{3-1},$$

不需要补充虚符号。每次合并三个最小概率，可得到一种三元 Huffman 码如下：

信源符号	x_1	x_2	x_3	x_4	x_5	x_6	x_7
p_i	0.20	0.18	0.10	0.10	0.10	0.061	0.059
码字	22	21	10	11	12	01	00
n_i	2	2	2	2	2	2	2

信源符号	x_8	x_9	x_{10}	x_{11}	x_{12}	x_{13}
p_i	0.04	0.04	0.04	0.04	0.03	0.01
码字	022	200	201	202	021	020
n_i	3	3	3	3	3	3

因此平均码长为

$$\begin{aligned}\bar{n}_3 &= 2(0.20 + 0.18 + 0.10 + 0.10 + 0.10 + 0.061 + 0.059) \\ &\quad + 3(0.04 + 0.04 + 0.04 + 0.04 + 0.03 + 0.01) \\ &= 2.20.\end{aligned}$$

三元码的效率为

$$\eta_3 = \frac{H(U)}{\bar{n}_3 \log 3} = \frac{3.35454}{2.20 \log 3} \approx 0.96204.$$

等价地，若以三元单位表示信源熵，

$$H_3(U) = \frac{H(U)}{\log 3} \approx 2.11648,$$

则

$$\eta_3 = \frac{H_3(U)}{\bar{n}_3} \approx \frac{2.11648}{2.20} \approx 0.96204.$$

3.16

设一个马尔可夫信源，其状态图如习题 3.16 图所示。

(a) 求稳态下各状态概率 $q(i)$ ，以及各字母 a_i 的出现概率， $i = 1, 2, 3$ 。(b) 求 $H(U|s_i)$ ， $i = 1, 2, 3$ 。(c) 求 $H_\infty(U)$ 。(d) 对各状态 S_j 求最佳二源码。(e) 计算平均码长。

解：由题图读得状态转移关系为

$$\begin{aligned} S_1 \rightarrow S_2 : a_1, \frac{1}{2}; a_2, \frac{1}{4}, \quad S_1 \rightarrow S_3 : a_3, \frac{1}{4}, \\ S_2 \rightarrow S_2 : a_2, \frac{1}{2}, \quad S_2 \rightarrow S_3 : a_3, \frac{1}{2}, \quad S_3 \rightarrow S_1 : a_1, 1. \end{aligned}$$

(a) 状态转移矩阵为

$$\mathbf{P} = \begin{pmatrix} 0 & \frac{3}{4} & \frac{1}{4} \\ 0 & \frac{1}{2} & \frac{1}{2} \\ 1 & 0 & 0 \end{pmatrix}.$$

设稳态概率为

$$\mathbf{q} = (q_1, q_2, q_3),$$

则

$$\mathbf{q} = \mathbf{qP}, \quad q_1 + q_2 + q_3 = 1.$$

由此解得

$$q_1 = \frac{2}{7}, \quad q_2 = \frac{3}{7}, \quad q_3 = \frac{2}{7}.$$

即

$$q(S_1) = \frac{2}{7}, \quad q(S_2) = \frac{3}{7}, \quad q(S_3) = \frac{2}{7}.$$

各字母出现概率为

$$\begin{aligned} P(a_1) &= q_1 \cdot \frac{1}{2} + q_3 \cdot 1 = \frac{2}{7} \cdot \frac{1}{2} + \frac{2}{7} = \frac{3}{7}, \\ P(a_2) &= q_1 \cdot \frac{1}{4} + q_2 \cdot \frac{1}{2} = \frac{2}{7} \cdot \frac{1}{4} + \frac{3}{7} \cdot \frac{1}{2} = \frac{2}{7}, \\ P(a_3) &= q_1 \cdot \frac{1}{4} + q_2 \cdot \frac{1}{2} = \frac{2}{7} \cdot \frac{1}{4} + \frac{3}{7} \cdot \frac{1}{2} = \frac{2}{7}. \end{aligned}$$

所以

$$P(a_1) = \frac{3}{7}, \quad P(a_2) = \frac{2}{7}, \quad P(a_3) = \frac{2}{7}.$$

(b) 状态 S_1 下的输出分布为

$$P(a_1|S_1) = \frac{1}{2}, \quad P(a_2|S_1) = \frac{1}{4}, \quad P(a_3|S_1) = \frac{1}{4}.$$

因此

$$H(U|S_1) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{4} \log \frac{1}{4} - \frac{1}{4} \log \frac{1}{4} = \frac{3}{2}.$$

状态 S_2 下

$$P(a_2|S_2) = \frac{1}{2}, \quad P(a_3|S_2) = \frac{1}{2},$$

所以

$$H(U|S_2) = 1.$$

状态 S_3 下

$$P(a_1|S_3) = 1,$$

所以

$$H(U|S_3) = 0.$$

综上,

$$H(U|S_1) = \frac{3}{2}, \quad H(U|S_2) = 1, \quad H(U|S_3) = 0.$$

(c) 马尔可夫信源熵率为

$$H_\infty(U) = \sum_{i=1}^3 q_i H(U|S_i).$$

代入上面的结果, 得

$$H_\infty(U) = \frac{2}{7} \cdot \frac{3}{2} + \frac{3}{7} \cdot 1 + \frac{2}{7} \cdot 0 = \frac{3}{7} + \frac{3}{7} = \frac{6}{7}.$$

因此

$$H_\infty(U) = \frac{6}{7} \text{ bit/符号}.$$

(d) 对每个状态分别作最佳二元码。

状态 S_1 下, 输出分布为

$$a_1 : \frac{1}{2}, \quad a_2 : \frac{1}{4}, \quad a_3 : \frac{1}{4}.$$

可取最佳二元码

$$a_1 : 0, \quad a_2 : 10, \quad a_3 : 11,$$

平均码长为

$$L_1 = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{4} \cdot 2 = \frac{3}{2}.$$

状态 S_2 下, 输出分布为

$$a_2 : \frac{1}{2}, \quad a_3 : \frac{1}{2}.$$

可取最佳二元码

$$a_2 : 0, \quad a_3 : 1,$$

平均码长为

$$L_2 = 1.$$

状态 S_3 下只有

$$a_1 : 1.$$

若允许空码, 则可取

$$a_1 : \emptyset,$$

平均码长为

$$L_3 = 0.$$

(e) 允许空码时，总平均码长为

$$\bar{L} = \sum_{i=1}^3 q_i L_i = \frac{2}{7} \cdot \frac{3}{2} + \frac{3}{7} \cdot 1 + \frac{2}{7} \cdot 0 = \frac{6}{7}.$$

因此

$$\bar{L} = \frac{6}{7} \text{ bit/符号}.$$

此时

$$\bar{L} = H_{\infty}(U) = \frac{6}{7}.$$